

深度学习

2023年10月

案例： 迁移学习

2

- 迁移学习的核心思想：

利用已有的知识和经验，来帮助解决新的问题。


从概率的角度来看，迁移学习可以理解为在不同的概率分布之间进行知识的迁移。



案例：迁移学习

3

为什么要“迁移”？



大数据与弱标注

大数据与弱计算

普适化与个性化

案例： 迁移学习

4

什么是迁移学习？

Definition 1 (*Transfer Learning*) Given a source domain $\mathcal{D}_S$ and learning task $\mathcal{T}_S$, a target domain $\mathcal{D}_T$ and learning task $\mathcal{T}_T$, *transfer learning* aims to help improve the learning of the target predictive function $f_T(\cdot)$ in $\mathcal{D}_T$ using the knowledge in $\mathcal{D}_S$ and $\mathcal{T}_S$, where $\mathcal{D}_S \neq \mathcal{D}_T$, or $\mathcal{T}_S \neq \mathcal{T}_T$.

给定一个源域和一个目标域，这两个领域的数据分布不同，迁移学习借助源域的知识，来帮助目标域知识的学习

案例：迁移学习

5

- 领域(Domain): 是进行学习的主体。领域主要由两部分构成：特征空间 X 和生成这些数据的概率分布 $P(X)$ 。通常我们用 D 来表示一个domain，用 P 来表示一个概率分布。特别地，因为涉及到迁移，所以对应于两个基本的领域：源领域(Source Domain) 和目标领域 (Target Domain)。通常我们用 D_s 表示源领域， D_t 表示目标领域。

域(domain) $D = \{\mathcal{X}, P(X)\}$ $\mathcal{X}$ 表示特征空间, $P(X)$ 表示边际概率分布, 其中 $X = \{x_1, \dots, x_n\} \in \mathcal{X}$

- 任务(Task): 是学习的目标。任务主要由两部分组成：标记空间 Y 和标签对应的函数 f 。通常我们用 Y 来表示一个标签空间，用 $f(\cdot)$ 来表示一个学习函数。相应地，源领域和目标领域的类别空间就可以分别表示为 Y_s 和 Y_t 。

任务(task) $T = \{y, f(\cdot)\}$ y 表示标签空间, $f(\cdot)$ 表示目标预测函数

案例： 迁移学习

6

- 确定源域；也就是从哪里迁移？
- 确定目标域；也就是迁移到哪里？要解决目标域的什么问题？
- 确定源域和目标域有什么联系？也就是迁移什么的问题？
- 确定如何进行有效迁移，避免负迁移？

案例：迁移学习

7

- 给定源领域 D_s 和源任务 T_s ，目标领域 D_t 和目标任务 T_t ，迁移学习的目标是在 $D_s \neq D_t$ 或者 $T_s \neq T_t$ 的情况下，用 D_s 和 T_s 的知识，来提升目标任务学习函数 $f_t(\cdot)$ 的预测效果。
- 根据迁移学习的定义进行分类，迁移学习大致分为如下几个类型。
 - (1) 特征空间的异同：即 X_s 和 X_t 是否相同；
 - (2) 特征分布的异同：即 $P_s(x)$ 和 $P_t(x)$ 是否相同；
 - (3) 标记空间的异同：即 Y_s 和 Y_t 是否相同；
 - (4) 条件概率分布的异同：即 $P_s(y|x)$ 和 $P_t(y|x)$ 是否相同。


案例：迁移学习

8

(1) 特征空间的异同：即 X_s 和 X_t 是否相同；

如果两个领域的数据具有相同的特征表示，这可能会使得迁移学习相对容易一些，因为可以直接利用源领域的特征提取方法。

如果 X_s 和 X_t 不同，就需要寻找合适的方法将源领域的特征转换到目标领域的特征空间，或者学习一个通用的特征表示来适应两个领域。



案例：迁移学习

9

(2) 特征分布的异同：即 $P_s(x)$ 和 $P_t(x)$ 是否相同；

如果两个领域的特征分布相似，那么源领域的知识可能更容易迁移到目标领域。

例如，在自然语言处理中，如果源领域和目标领域的文本数据具有相似的词频分布和主题分布，那么特征分布相似。

如果特征分布不同，可能需要进行分布对齐或者采用更复杂的迁移策略。

案例： 迁移学习

10

(3) 标记空间的异同：即 Y_s 和 Y_t 是否相同；

两个领域的任务具有相同的类别标签，这在迁移学习中是比较理想的情况。

例如，在不同地区的同一类型的图像分类任务中，标记空间可能相同。

如果 Y_s 和 Y_t 不同，可能需要进行标签映射或者采用无监督的迁移学习方法。

案例：迁移学习


11

(4) 条件概率分布的异同：即 $P_s(y|x)$ 和 $P_t(y|x)$ 是否相同

如果两个领域的条件概率分布相似，这意味着在两个不同的领域中，对于特定的输入特征，其对应输出为特定标签的可能性较为接近。

如果两个领域的条件概率分布不同，那么就意味着在源领域中有效的分类规则在目标领域中可能不再适用。

可以使用微调（fine-tuning）的方法，在源领域训练好的模型基础上，利用目标领域的少量数据对模型的部分参数进行调整，使其更好地适应目标领域的任务。



案例：迁移学习

12

- 边缘概率就是 $P(\mathbf{x})$ ，指的是产生数据的分布。条件概率是 $P(y|\mathbf{x})$ ，就是数据和标签之间的后验概率分布，和学习任务有关。
- $P(\mathbf{x})$ 不同是说数据产生的机制不同。例如不同光照背景角度照相机的图像和视频，不同用户产生的行为数据，不同主题的文本特征，等等。只要不是来自于同一个分布，边缘概率 $P(\mathbf{x})$ 就不一样。
- 在迁移学习中，只要源域和目标域数据服从不同的分布规律，我们就认为二者存在边缘概率分布差异，这种差异被称为分布偏移或领域漂移（domain shift）。

案例： 迁移学习

13

- 在理想情况下，源域和目标域的条件概率分布是相同的。然而，在现实中并不总是成立。例如，不同被试者的生理数据通常不一样；而且即使是相同被试者，在不同状态或者时间下，进行相同的动作，生理数据也存在差异。
- 迁移学习的分布适配distribution adaptation，指的就是去适配边缘和条件分布


案例： 迁移学习

14

- 如果源域和目标域在边缘概率分布上有较大差异，但在条件概率分布上差异较小，那么我们可能会选择使用特征选择或者特征转换的方法来进行迁移学习。
- 反之，如果源域和目标域在条件概率分布上有较大差异，那么我们可能需要使用更复杂的迁移学习方法，例如重新标注一些目标域的数据，或者使用对抗性训练等方法来解决这个问题。

案例：迁移学习

15



案例： 迁移学习

16

张三是一名工程师，有一天张三的主管告诉他，现在有个项目需要实现一个能实现黑底白字的手写字“5， 0， 4， 1”识别的模型，后天就要。


张三查看了公司已的数据库，发现已有的样本非常少，不足以支撑一个新模型的训练。

案例：迁移学习


17

如何理解迁移学习-举例

现在要分类手写字体5、0、4、1，但是没有足够的样本？怎么办？



加权



案例： 迁移学习

18


张三完成任务，第二天业务方又告知，现在需求变了，只想对黑底白字的“0”和“1”进行分类，明天给出结果。

这下子张三可为难了，上次两天时间差点没做完，这次就一天时间了。

案例：迁移学习

19

现在只想分类0、1怎么办？



案例： 迁移学习

20


张三完成任务之后的第二天，业务方告诉他需求又变了，现在是对“白底黑字”的“0”和“1”进行分类，而不是“黑底白字”，第二天要给出结果，他们会提供少量的白底黑字的素材。

案例：迁移学习

21

如何理解迁移学习-举例

现在只想对分类白底黑字0、1怎么办？




案例： 迁移学习

22

完成任务之后没多久，张三又又被告知需求变了，现在需要对没有标注的彩色背景“0”，“1”手写字体进行识别(注意是没有标注的，也就是没有label)，但是会提供一些素材，要求第二天给出结果。


现在想对没有标注的彩色背景的0、1分类怎么办?

[illegible]

案例：VAE(Variational AutoEncoders)


24

- 自编码AutoEncoder是一种无监督学习的算法，他利用反向传播算法，让目标值等于输入值。
- 输入一张图片，通过一个Encoder神经网络，输出一个比较"浓缩"的feature map。之后将这个feature map通过一个Decoder网络，又将这张图片还原回去
- 整个Encoder+Decoder是一个神经网络，中间的code只是暂存的数据




案例：VAE(Variational AutoEncoders)

25



案例：VAE(Variational AutoEncoders)

26




Real data

30-d deep autoencoder

案例：VAE(Variational AutoEncoders)

27


- 假设我们已经在 AutoEncoder 上训练了一个 6 维的 vector，这个 6 维的 vector 将学习面部的一些属性，例如肤色、是否戴眼镜等



案例：VAE(Variational AutoEncoders)

28


- 过往的各种 AutoEncoder 都是将输入数据转换为 vector，其中每个维度代表学习到的数据。而 Variational AutoEncoders (VAE) 提供了一种概率分布的描述形式，VAE 中 Encoder 描述的是每个潜在属性的概率分布，而不是直接输出一个值



案例：VAE(Variational AutoEncoders)


29

- 在上面的示例中，我们使用单个值来描述输入图像的潜在属性。但是，我们可能更喜欢将每个潜在属性表示为一个范围。VAE 就可以实现这个功能



案例：VAE(Variational AutoEncoders)


30



案例：VAE(Variational AutoEncoders)

31

- **Encoder** 接收输入数据，通过神经网络的处理，将其映射为潜在空间中的两个关键参数：**mean**（均值）和 **standard derivation**（标准差）。
- 同时，为了引入随机性，会在这个过程中加入一定的 **noise**（噪声）。
- **Decoder** 则以 **Encoder** 输出的 **mean**、**standard derivation** 和 **noise** 为基础，重构出与输入数据相似的输出。



预训练模型实践或VAE实践

- 分为8组，自行组队，每组6人。
- 每组汇报15分钟，包括演示代码运行
- 有5分钟答辩
- 12月16日 ~ 12月23日汇报，确定题目后登记任务名称和组员姓名，根据登记顺序汇报
- 要求：各小组任务不可重复，代码必须是可以顺利运行，ppt演示应包含模型介绍和小组分工。
- 代码跑通并且有结果分析占30%，汇报占45%，难度占20%，专业相关度占5%

预训练实践关键词：ResNet、
Pretrained model、预训练、微调等
VAE实践关键词：图像生成等
其他：GAN、GNN、DRL等